Rapport technique

YouTube Sentiment Lens

Analyse de sentiment YouTube avec TF-IDF, Logistic Regression, FastAPI, Chrome et Docker

Projet INDIA - Année 2026/27

1. Problématique et architecture

Objectif : analyser automatiquement les commentaires YouTube en temps réel.

Flux : Extension Chrome -> API FastAPI -> pipeline ML -> résultats et statistiques.

Déploiement : Docker exécuté dans GitHub Codespaces, port public 7860.

Versionnement : dépôt GitHub sur la branche main.

2. Données et préparation

Source : Reddit Sentiment Analysis.

37 149 commentaires téléchargés; 36 562 conservés après nettoyage.

Labels : -1 négatif, 0 neutre, 1 positif.

Split stratifié reproductible : 80 % train / 20 % test.

Nettoyage : URLs, mentions, hashtags et caractères spéciaux normalisés.

3. Modèle et optimisation

Vectorisation TF-IDF avec Logistic Regression pondérée par classe.

Comparaison effectuée avec Linear SVM.

GridSearchCV utilisé sur C, min_df et ngram_range.

Meilleurs paramètres : C=2.0, min_df=2, ngram_range=(1,1).

4. Résultats

Accuracy : 87,79 % (seuil demandé : 80 %).

F1 négatif : 81,18 %.

F1 neutre : 90,79 %.

F1 positif : 88,69 %.

F1 macro : 86,89 %.

Inférence de 50 commentaires : 3,57 ms (seuil : 100 ms).

5. API et extension

GET /health vérifie le chargement du modèle.

POST /predict_batch valide un batch de 1 à 500 commentaires.

La réponse contient le label, le sentiment, la confiance et les statistiques.

L'extension extrait les commentaires visibles, propose des filtres, le mode sombre et la copie.

6. Tests et déploiement

Tests automatisés : 3 passed.

Docker build validé localement.

Codespaces : port 7860 rendu public.

Health public vérifié : status=ok, model_loaded=true.

Swagger /docs vérifié avec les deux endpoints.

7. Captures et conclusion

Les captures Playwright jointes montrent /health, Swagger et les modes clair/sombre de l'extension.

Le projet respecte les seuils ML et les exigences fonctionnelles.

Limite : Codespaces est éphémère; il doit rester actif pendant la démonstration.

Améliorations : monitoring, authentification, cache et mise à jour versionnée du modèle.

Capture Playwright - API health

Capture Playwright - Swagger

Capture Playwright - Extension

Capture Playwright - Mode sombre